

Identificação de severidade em sistemas convectivos de mesoescala usando redes neurais recorrentes e convolucionais

Adriano P. Almeida¹

¹Programa de Pós Graduação em Computação Aplicada
Instituto Nacional de Pesquisas Espaciais (INPE)

Abstract. *Lightning strikes are natural phenomena characteristic of severe thunderstorms and can pose great risks, being responsible for many socio-economic problems. This work aims to apply two approaches of artificial neural networks to identify and predict severity in convective mesoscale systems.*

Resumo. *As descargas elétricas atmosféricas são fenômenos naturais característicos de tempestades severas e podem oferecer grandes riscos, sendo responsáveis por diversos problemas socioeconômicos. Este trabalho tem como objetivo aplicar duas abordagens de redes neurais artificial para fazer a identificação e previsão de severidade em sistemas convectivos de mesoescala.*

1. Introdução

Os sistemas convectivos de mesoescala são fenômenos meteorológicos caracterizados por um grande acumulado de nuvens com regiões de precipitação, podendo essas serem moderadas e com distribuição uniforme (estratiforme), ou fortes e com regiões de intensidades acompanhadas por raios (convectivas) [Houze and Robert 2004]. Em ciências atmosféricas, a escala define alguns aspectos importantes que são levados em consideração nos estudos da atmosfera, quanto à área, período de abrangência e métodos empregados na busca dos objetivos [Nunes 1998]. As definições de escala mais aceitas na literatura são as propostas por [Orlanski 1975], em que foram reduzidas à microescala, macroescala e mesoescala, sendo essa última, a que será abordada neste trabalho.

Na mesoescala são observados os eventos meteorológicos que possuem tempo de vida entre 1 a 7 dias, nas altitudes de 2 km a 2000 km e com grande extensão horizontal e vertical [Orlanski 1975]. Esses sistemas são observados por radares e satélites meteorológicos. O satélite meteorológico GOES-16 (*Geostationary Operational Environmental Satellite*) atualmente é um dos principais instrumentos de observação de sistemas convectivos de mesoescala. O GOES-16 é um satélite geoestacionário que está sobre o equador no hemisfério ocidental, fornecendo informações a cerca das condições da atmosfera a curto prazo [Chinchay 2018].

A bordo do satélite GOES-16 estão os instrumentos ABI (*Advanced Baseline Imager*) e GLM (*Geostationary Lightning Mapper*). O ABI possui 16 bandas espectrais operando em diferentes comprimentos de onda, e podem monitorar características distintas da atmosfera e superfícies. O GLM é o instrumento que mede a radiância do topo das nuvens a fim de identificar ocorrência de descargas elétricas, agrupando os dados em três produtos: eventos, grupos e flashes. O evento é computado a partir de um pixel que excede um determinado limiar de energia, o grupo é definido como um conjunto de eventos, e os flashes um conjunto de grupos, esses agrupamentos são criados a partir do algoritmo de clusterização LCFA (*Lightning Cluster Filter Algorithm*) [Goodman et al. 2013].

O objetivo deste trabalho é aplicar técnicas computacionais para identificação de severidade em sistemas convectivos de mesoescala a partir de dados coletados pelo satélite geostacionário GOES-16. Para isso será utilizada uma rede neural convolucional para classificar a intensidade média da temperatura do topo das nuvens em imagens do ABI e a rede neural recorrente para previsão da densidade de descargas elétricas a curto prazo usando dados do GLM.

2. Descrição dos dados

Nesse trabalho foram utilizados os dados do canal 13 do instrumento ABI, que opera com comprimento de onda em $10.35 \mu m$ e mede a radiância emitida pela temperatura de brilho do topo das nuvens a cada 10 minutos. Através desse canal é possível identificar nuvens formadas exclusivamente por cristais de gelo, já que elas possuem temperaturas mais baixas [Chinchay 2018]. Para cada cena obtida a partir do satélite, foram extraídas imagens com a projeção de cada estado brasileiro.

Além disso, também foram utilizados os dados do produto flash, obtido a partir do instrumento GLM do GOES-16. Esse instrumento fornece as coordenadas (longitude e latitude) para seus produtos a cada 20 segundos, sendo assim, foi necessário fazer o acumulado de raios a cada 10 minutos, a fim de sincronizar com a resolução temporal do ABI. Para todo estado brasileiro também foi computado o total de raios a cada tempo.

Os dados foram baixados a partir da AWS CLI (*Amazon Web Service Command Line Interface*)¹ e são referentes ao período de 4 e 5 de dezembro de 2019, data em que foram observadas ocorrências de tempestades em várias regiões do Brasil.

3. Metodologia

A linguagem de programação utilizada neste trabalho foi o Python 3², usando para criação dos modelos a biblioteca Keras³ e Scikit-learn⁴. Foram utilizadas duas metodologias diferentes neste trabalho, porém, com propósitos semelhantes, que é identificar a severidade de sistemas convectivos de mesoescala. A primeira delas foi aplicar a rede neural convolucional para classificar a intensidade da temperatura das nuvens a partir dos dados do canal 13 do ABI. A segunda abordagem consistiu em aplicar a rede neural recorrente para fazer a previsão da densidade de descargas elétricas a curto prazo, baseado nos dados dos tempos anteriores do produto flash do GLM. Essas abordagens serão abordadas separadamente ao longo desta seção.

3.1. Rede neural convolucional

A rede neural convolucional foi utilizada neste trabalho a fim de classificar imagens de topo das nuvens que possam possuir características de severidade, levando em consideração a sua temperatura. Para isso, foram criadas quatro classes representando as intensidades das temperaturas registradas pelas imagens em cada tempo para todos os estados brasileiros. As classes foram criadas com base na distribuição dos valores, utilizando medidas de percentis.

¹<https://registry.opendata.aws/noaa-goes/>

²<https://www.python.org>

³<https://keras.io>

⁴<https://scikit-learn.org>

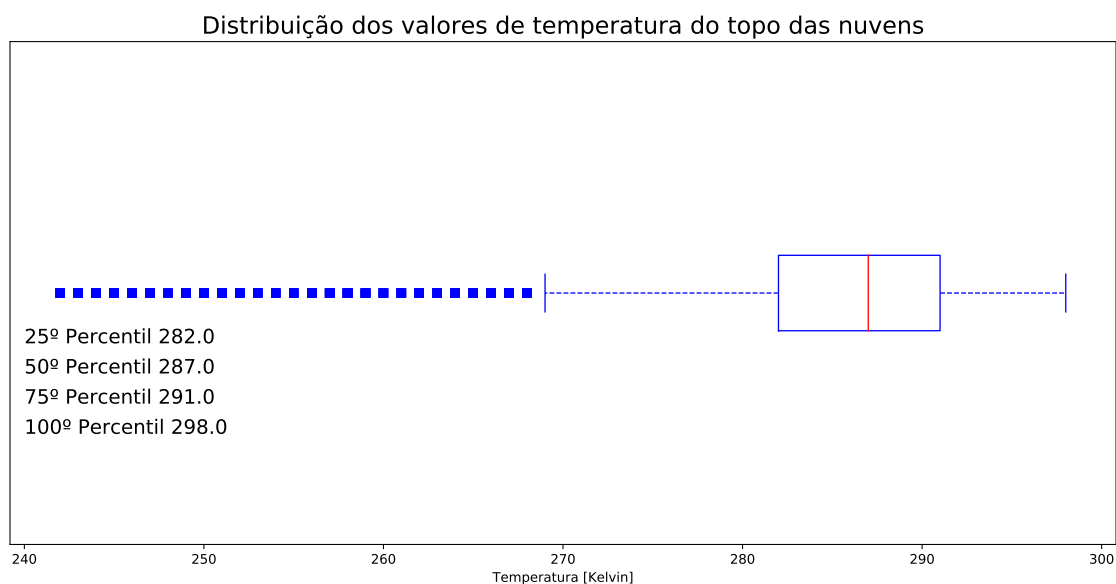


Figura 1. Distribuição dos valores de temperatura do topo das nuvens e percentis destacados para criação das classes

O gráfico da Figura 1 mostra os percentis definidos para a criação das classes. O primeiro quartil representando os valores de temperatura menos frequentes, foi utilizado para criar a primeira classe (nuvens muito frias), sendo essas, as nuvens com temperatura mais intensa, com o valores máximos de 282° K. A segunda classe (nuvens frias) classe foi criada com base no segundo quartil e possui valores de temperatura entre 283° K e 287°K. Para a quarta classe (nuvens quentes) foram utilizados os valores do 3 quartil com valores entre 289° K e 291°K. Por fim, foram utilizados valores acima de 291° K para representar a quarta classe (nuvens muito quentes), sendo essas as nuvens que provavelmente não possuem severidade devido a sua alta temperatura.




Figura 2. Esquema da arquitetura da rede neural convolucional

Após realizar o pré-processamento e a definição das classes, foi configurada a arquitetura da rede neural convolucional conforme ilustrada na Figura 2. Todas as imagens foram redimensionadas para o tamanho de 128x128 e os valores de cada pixel normalizados entre 0 e 1 a fim de aliviar o a carga de processamento da rede neural. Foram utilizados 32 filtros com *kernels* de 16x16 e a função de ativação *ReLU* na camada de convolução para que fossem identificadas os núcleos mais frios das nuvens. A fim de destacar mais os aspectos identificados pelos filtros da camada de convolução, foi aplicada

uma camada de *Max pooling* reduzindo os mapas de características para as dimensões de 8x8. Em seguida foi adicionada a camada de *Flatten* para transformar os mapas de características em vetores para servirem de entrada para a rede densa.

Na rede neural densa foram utilizadas duas camadas ocultas, cada uma com 32 neurônios, e a fim de evitar o *overfitting* foi adicionado 30% de *dropout* em ambas. Na camada de saída foram adicionados 4 neurônios, representando a probabilidade da imagem processada ser de determinada classes. Foi utilizada nas camadas ocultas a função de ativação *ReLU* e na camada de saída a função *softmax*. A função de perda utilizada para avaliar o erro do modelo foi a *categorical cross entropy* e o otimizador Adam com a taxa de aprendizagem (η) em 0.001.

Durante o treinamento do modelo foram utilizadas duas abordagens para a sua avaliação. A primeira abordagem foi a separação dos dados em conjuntos de teste (15%), treinamento (75%) e validação (10%), e ao final analisar o desempenho das classificações do modelo utilizando as métricas da matriz de confusão. A segunda abordagem para a avaliação do modelo foi aplicar a validação cruzada, separando os dados em 10 *folds*.

3.2. Rede neural recorrente

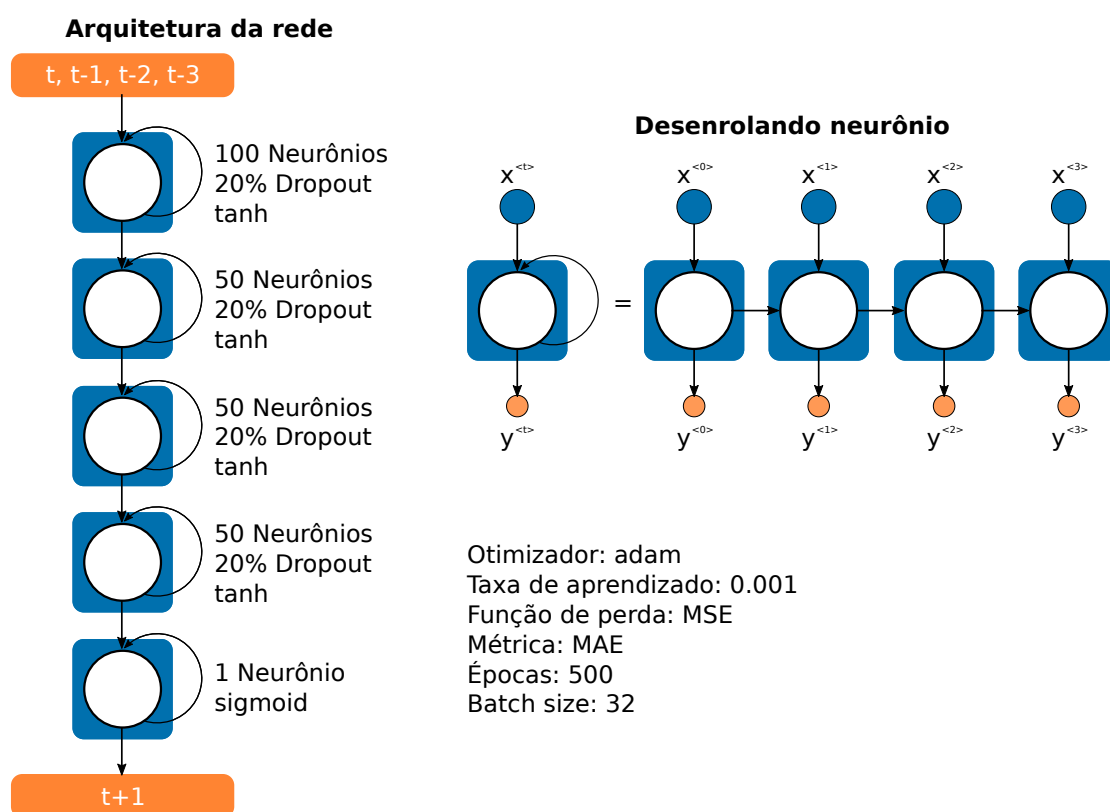


Figura 3. Esquema da arquitetura da rede neural convolucional

A rede neural recorrente utilizada neste trabalho foi a LSTM (*Long Short-Term Memory*), e foi utilizada para prever a densidade de descargas elétricas nos 10 minutos a frete em cada estado brasileiro. Para cada estado brasileiro foi acumulado o total de raios que aconteceram em 10 minutos a partir dos dados do produto flash do GLM a bordo

do GOES-16. A rede foi treinada para estimar o total de descargas elétricas a partir do acumulado dos últimos quatro tempos, incluindo o tempo atual.

A Figura 3 mostra informações sobre a arquitetura da rede neural recorrente utilizada. Na primeira camada interna da rede foram adicionados 100 neurônios com 20% de *dropout*, para segunda, terceira e quarta camada foram adicionados 50 neurônios com *dropout* também de 20%. Para todas as camadas internas foi utilizada a função de ativação tangente hiperbólica. Na camada de saída foi utilizado um neurônio com a função de ativação sigmoide. A função de ativação sigmoide pôde ser utilizada, pois os dados estavam normalizados entre 0 e 1, tendo com essa, um desempenho melhor do que utilizando a função de ativação linear. Foi utilizado na rede o otimizador Adam com a taxa de aprendizado (η) definido em 0.001. A função de perda utilizada foi o MSE (*Mean Squared Error*) e a métrica analisada sendo MAE (*Mean Absolute Error*). A rede foi treinada em 500 épocas utilizando lotes de 32, 15% dos dados pra teste, 75% pra treinamento e 10% pra validação.

Durante os testes utilizando LSTM, foram utilizados somente os dados de raios descargas elétricas a fim de estimar a tendência da série temporal em um tempo futuro com base nos tempos anteriores. Sendo assim, foi observado comportamentos diferentes nas séries temporais em cada estado, tornando modelos de alguns estados incompatíveis para serem utilizados em outros. Com isso, para os testes realizados nesse trabalho foram criados modelos para cada estado, avaliando-os assim de forma independente. Afim de buscar uma correlação entre os estados, para que no futuro seja utilizado um modelo treinado para mais estados sem grandes incoerências, foi aplicado sem muito aprofundamento a rede SOM (*Self Organizing Maps*) [Kohonen 1982], onde foi possível identificar alguns estados com comportamentos de suas séries temporais de raios semelhantes. Foram criados dois mapas utilizando a rede SOM, um deles agrupando as séries temporais por estado e outro por região, ambos com as dimensões 5x5.

4. Resultados

As metodologias descritas na seção anterior foram fundamentais para o desenvolvimento deste trabalho, nesta seção serão apresentados os resultados obtidos. Como na seção de metodologia, os resultados também serão apresentados de forma individual.

4.1. Identificação de severidade em nuvens




Figura 4. Gráficos da função de perda e acurácia no treinamento da CNN.

A identificação da severidade nas nuvens foi feita com base na classificação das imagens do topo das nuvens utilizando a rede neural convolucional, para isso foram definidos os limiares descritos anteriormente. A primeira abordagem de treinamento utilizando essa rede, foi separar os dados em conjuntos de treinamento, validação e teste. Após realizar testes com alguns hiper-parâmetros, chegou-se na configuração que gerou o desempenho apresentado nos gráficos da Figura 4, um erro mínimo de 0.36 e acurácia chegando até a 88.57% no conjunto de validação, estabilizando-se por volta da 160ª época.




Figura 5. Matriz de confusão resultante da classificação do modelo para a intensidade de temperatura das nuvens do conjunto de teste.

O modelo foi avaliado com as métricas da matriz de confusão conforme mostrado na Figura 5. Foram classificadas corretamente 91.95%, 94.74%, 63.10% e 91.61% das imagens pertencentes às classes definidas: muito fria (C1), fria (C2), quente (C3) e muito quente (C4), respectivamente. A acurácia do modelo foi de 91.94%, aplicando a Equação 1 na matriz de confusão resultante.

$$Acurácia = \frac{\sum_i^j CiP}{\sum_i^j CiP + CiN} \quad (1)$$

Onde:

j são todas as classes definidas.

CiP é a total de imagens da classe i classificadas corretamente.

CiN é total de imagens da classe i classificadas de forma errada.

A segunda forma de avaliação do modelo de classificação das imagens, foi utilizando o método de validação cruzada. A Figura 6 mostra o esquema de como foi aplicado esse método de avaliação. Os dados foram divididos em 10 partes (*folds*), ficando com a acurácia média de 87%, sendo o melhor desempenho no *fold* 4 com 97.54% e pior no *fold* 8 com 29.50%.




Figura 6. Esquema da validação cruzada na classificação da intensidade de temperatura das imagens.

4.2. Estimativa da densidade de descargas elétricas

Para a estimativa de descargas elétricas foi utilizada a rede neural recorrente LSTM. Como mencionado anteriormente, foi criado um modelo para cada um dos estados, sendo assim serão apresentados somente alguns dos modelos, a fim de evitar redundâncias, haja vista que alguns modelos ficaram com as métricas de avaliação praticamente iguais.




Figura 7. Total de raios previstos pelo modelo em função do total observado e série temporal com o total de raios previstos e observados no estado MT.

De forma geral, os modelos acompanharam bem as tendências do total de raios, algumas vezes subestimando ou superestimando com uma pequena diferença, e outras vezes sendo bastante precisos, principalmente quando a densidade de raios é baixa. As Figuras 7 e 8 mostram esses comportamentos, com as previsões feitas pelo modelo e o total de raios observados nos estados de Mato Grosso e Mato Grosso do Sul, respectivamente. As Figuras 9 e 10 mostram as curvas de perda e acurácia durante o treinamento dos modelos dos dois estados.

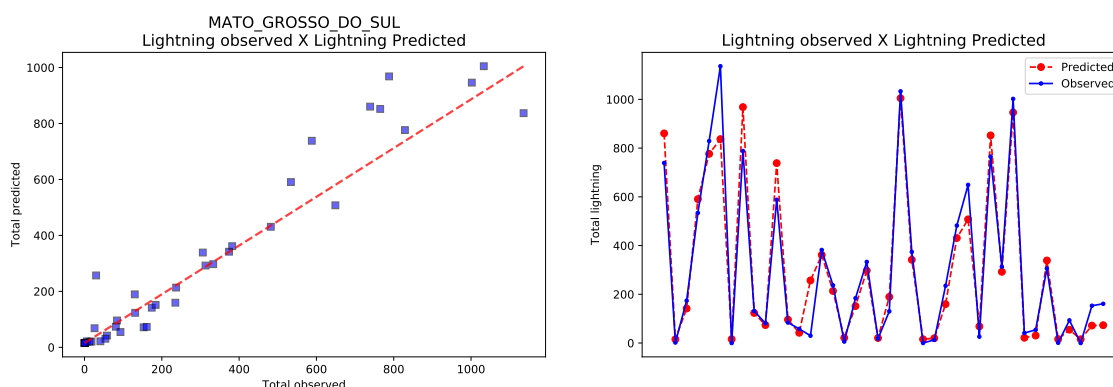


Figura 8. Total de raios previstos pelo modelo em função do total observado e série temporal com o total de raios previstos e observados no estado MS.




Figura 9. Curva da função de perda e acurácia durante o treinamento e validação da rede para o estado Mato Grosso.




Figura 10. Curva da função de perda e acurácia durante o treinamento e validação da rede para o estado Mato Grosso do Sul.

Os modelos treinados para os estados da região norte, região onde foram detectados mais descargas elétricas durante o período analisado, também conseguiram acompanhar bem a tendência da densidade de raios, como mostrado nas Figuras 11 e 12, Pará e Amazonas respectivamente. As Figuras 13 e 14 mostram os gráficos da função de perda e acurácia para os conjuntos de treinamento e validação dos estados. Embora tenha sido utilizada somente uma variável, a rede neural recorrente se mostrou bastante eficiente nas estimativas de descargas elétricas a curto prazo, conforme pode ser observado nas figuras.

Por ter sido analisado um período curto, e devido às condições climáticas de alguns estados, alguns não pôde ser avaliado de forma eficiente. Alguns estados da região




Figura 11. Total de raios previstos pelo modelo em função do total observado e série temporal com o total de raios previstos e observados no estado PA.

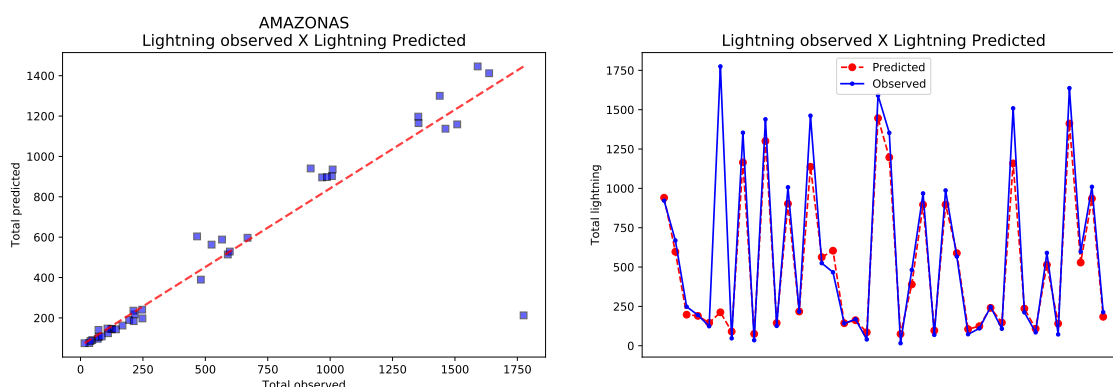


Figura 12. Total de raios previstos pelo modelo em função do total observado e série temporal com o total de raios previstos e observados no estado AM.




Figura 13. Curva da função de perda e acurácia durante o treinamento e validação da rede para o estado Pará.

nordeste, foram os estados que mais apresentaram essas características. As Figuras 15 e 16 mostram a avaliação das previsões do modelo em função do total de raios observadas para os estados Alagoas e Rio Grande do Norte, respectivamente. E as Figuras 17 e 18 mostram as curvas de perda e acurácia durante o treinamento e validação.




Figura 14. Curva da função de perda e acurácia durante o treinamento e validação da rede para o estado Amazonas.




Figura 15. Total de raios previstos pelo modelo em função do total observado e série temporal com o total de raios previstos e observados no estado AL.




Figura 16. Total de raios previstos pelo modelo em função do total observado e série temporal com o total de raios previstos e observados no estado RN.




Figura 18. Curva da função de perda e acurácia durante o treinamento e validação da rede para o estado Rio Grande do Norte.




Figura 17. Curva da função de perda e acurácia durante o treinamento e validação da rede para o estado Alagoas.

5. Considerações finais

Neste trabalho foram aplicadas duas abordagens utilizando redes neurais artificiais para identificar severidade em sistemas convectivos de mesoescala. Na primeira abordagem foi aplicada a rede rede neural convolucional para classificar imagens do canal 13 do satélite GOES-16 em quatro limiares diferentes de temperatura. Na segunda abordagem, foi aplicada a rede neural recorrente LSTM para fazer a estimativa a curto prazo de descargas elétricas. Ambas as abordagens apresentaram bons resultados, a rede neural convolucional tendo acurácia média de 87% na validação cruzada e a rede neural recorrente acompanhando bem a densidade de raios dos estados.

Como perspectivas de trabalhos futuros pretende-se adicionar variáveis de mais canais e de outras fontes de dados, afim de realizar previsões com prazos maiores. Além disso, utilizar séries temporais maiores, o que não foi possível neste trabalho devido às limitações de processamento. De forma geral, os modelos desenvolvidos neste trabalho apresentaram bons resultados após terem passados por vários ajustes de hiper-parâmetros (*fine-tuning*), podendo ser melhorado ainda mais com as futuras melhorias aqui descritas e se tornar um produto operacional auxiliando entidades responsáveis em tomadas de decisões.

Referências

- Chinchay, J. H. H. (2018). Uso de multi-canais do goes-16 para previsão imediata de densidade de descargas elétricas. Dissertação de mestrado, Instituto Nacional de Pesquisas Espaciais (INPE).
- Goodman, S. J., Blakeslee, R. J., Koshak, W. J., Mach, D., Bailey, J., Buechler, D., Carey, L., Schultz, C., Bateman, M., McCaul Jr, E., et al. (2013). The goes-r geostationary lightning mapper (glm). *Atmospheric research*, 125:34–49.
- Houze, J. and Robert, A. (2004). Mesoscale convective systems. *Reviews of Geophysics*, 42(4).
- Kohonen, T. (1982). Self-organized formation of topologically correct feature maps. *Biological Cybernetics*, 43.
- Nunes, L. H. (1998). A escala nas ciências atmosféricas. *Revista do Instituto Geológico*, 19(1-2):71–73.

Orlanski, I. (1975). A rational subdivision of scales for atmospheric processes. *Bulletin of the American Meteorological Society*, pages 527–530.